

## Lista 2

**Exercício 1.** Suponha que  $X \sim N(7, 25)$ . Em uma amostra de tamanho  $N = 100$ , calcule  $Pr(6 < X < 8)$  e  $Pr(6 < \bar{X} < 8)$ . Explique por que as probabilidades diferem.

Resposta: Para uma amostra de tamanho  $N = 100$ , temos que

$$\bar{X} \sim N\left(7, \frac{25}{100}\right) \iff \bar{X} \sim N\left(7, \frac{1}{4}\right)$$

Logo, as probabilidades são:

$$\begin{aligned} Pr[6 < X < 8] &= Pr\left[-\frac{1}{5} < \frac{x-7}{5} < \frac{1}{5}\right] = 0,159 \\ Pr[6 < \bar{X} < 8] &= Pr\left[-2 < \frac{\bar{x}-7}{5} < 2\right] = 0,954 \end{aligned}$$

Diferem por conta da menor variância da média. Conforme  $N$  cresce, valores da média próximos à esperança ficam cada vez mais prováveis (princípio LGN).  $\square$

**Exercício 2.** Suponha que dois estatísticos queiram estimar um parâmetro  $\theta > 0$  desconhecido. O estatístico A observa apenas uma realização  $x = 2$  de uma variável aleatória  $X \sim \text{Gamma}(3, \theta)$ , ao passo que o estatístico B observa uma realização  $y = 3$  de  $Y \sim \text{Poisson}(2\theta)$ . Mostre que as funções de verossimilhança determinadas pelas duas situações são proporcionais e, portanto, terão mesmo valor máximo. Qual o valor de  $\hat{\theta}$  obtido por ambos nesse caso?

Resposta: A densidade de  $X \sim \Gamma(3, \theta)$  é dada por

$$f(x) = \frac{\theta^3}{\Gamma(3)} x^2 e^{-\theta x},$$

então, para  $x = 2$ , segue que

$$f(2) = \frac{\theta^3}{\Gamma(3)} 2^2 e^{-2\theta} = \frac{4}{\Gamma(3)} \theta^3 e^{-2\theta}.$$

Já a densidade de  $Y \sim \text{Poisson}(2\theta)$  é

$$g(y) = \frac{e^{-2\theta} (2\theta)^y}{y!},$$

que, para  $y = 3$ , temos

$$g(3) = \frac{4}{3} \theta^3 e^{-2\theta} \propto f(2)$$

Precisamos mostrar que as funções de verossimilhança proporcionais, tais que

$$\arg \max_{\theta > 0} k\theta^3 e^{-2\theta} = \hat{\theta} = \arg \max_{\theta > 0} 2 \ln \theta - 2\theta$$

Resolvendo por CPO, temos:

$$\frac{\partial k\theta^3 e^{-2\theta}}{\partial \theta} = k e^{-2\theta} \theta^2 (2\theta - 3) = 0$$

$$\hat{\theta} = \frac{3}{2} \quad (\text{pois } \theta > 0)$$

$$\frac{\partial 2 \ln \theta - 2\theta}{\partial \theta} = \frac{2}{\theta} - 2 = 0$$

$$\hat{\theta} = \frac{3}{2}$$

□

**Exercício 3.** Suponha que  $Y_1$  e  $Y_2$  sejam variáveis aleatórias independentes, com esperança comum,  $\mu$ , mas variâncias distintas (e conhecidas),  $\sigma_1^2$  e  $\sigma_2^2$ . Você deseja estimar  $\mu$  através de uma média ponderada de  $Y_1$  e  $Y_2$ , isto é,  $\hat{\mu} = \alpha Y_1 + (1 - \alpha) Y_2$ . Mostre que  $\hat{\mu}$  é não viesado e obtenha o valor de  $\alpha$  que minimiza a variância de  $\hat{\mu}$ . Elabore uma intuição para seu resultado.

Resposta:

$$E(\hat{\mu}) = \alpha E(Y_1) + (1 - \alpha) E(Y_2) = \mu(\alpha + 1 - \alpha) = \mu$$

$$Var(\hat{\mu}) = \alpha^2 \sigma_1^2 + (1 - \alpha)^2 \sigma_2^2$$

Para encontrar o valor de  $\alpha$  que minimiza a variância de  $\hat{\mu}$ , iremos solucionar

$$\hat{\alpha} = \arg \max_{\alpha \in [0,1]} Var(\hat{\mu})$$

por CPO:

$$2\hat{\alpha}\sigma_1^2 - 2(1 - \hat{\alpha})\sigma_2^2 = 0$$

$$\hat{\alpha} = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}$$

Intuição:

- V.A. com menor variância tem maior peso
- ainda assim, ambas têm peso positivo, pois conseguem conteúdo novo (independente) de informação sobre  $\mu$ .

□

**Exercício 4.** Suponha que  $X \sim \exp(\theta)$ , isto é, que  $f(x) = \theta e^{-\theta x}$ .

- a) Qual a esperança de  $X$ ? Como você construiria um estimador de método dos momentos de  $\theta$  usando essa informação?
- b) Qual a variância de  $X$ ? Como você construiria um estimador de método dos momentos de  $\theta$  usando essa informação?
- c) Você seria capaz de construir um estimador de  $\theta$  que utilizasse ao mesmo tempo as informações de (a) e (b)?
- d) Qual o estimador de Máxima Verossimilhança para  $\theta$ ? Ele é melhor ou pior do que os propostos nos itens (a)-(c)? Por quê?

Resposta:

- a)  $E(X) = \theta^{-1} \implies$  análogo amostral:  $\hat{\theta} = \frac{1}{\bar{x}}$
- b)  $V(X) = \theta^{-1} \implies$  análogo amostral:  $\hat{\theta} = \frac{1}{\frac{1}{N} \sum (x_i - \bar{x})^2}$
- c) De (a) e (b), temos na população:

$$\theta - E^{-1}(X) = 0 \quad \text{e} \quad \theta - V^{-1}(X) = 0$$

Seja

$$M = \begin{bmatrix} \theta - 1/\bar{x} \\ \theta - 1/\hat{V}(X) \end{bmatrix},$$

então quero encontrar  $\hat{\theta}$  que maximize a chance de  $M = [0 \ 0]'$ .

Seja  $W$  uma matriz positiva-definida de pesos, então o estimador é dado por

$$\hat{\theta} = \arg \min_{\theta > 0} M'(\theta) W M(\theta)$$

- d) A máxima verossimilhança é dada por

$$\mathcal{L}(\theta) = \prod_{i=1}^N \theta e^{-\theta x_i}$$

Logo, o estimador é

$$\hat{\theta} = \arg \max \left\{ N \ln \theta - \theta \sum x_i \right\}$$

Por CPO:

$$\hat{\theta} = \frac{1}{\bar{x}}$$

- Atinge o limite inferior de Cramer-Rao

- A fórmula é igual ao do item (a), mas as informações à priori de  $f(x)$  é que garante que  $\bar{x}^{-1}$  atinge o limite inferior de Cramer-Rao.

□

**Exercício 5.** Suponha que  $f(x) = (\alpha + 1)x^\alpha$  para  $x \in [0, 1]$ .

- a) Proponha um estimador de método dos momentos para  $\alpha$  que use  $E(X)$  como informação obtida à priori.
- b) Se sua amostra for  $X = [0, 1 \quad 0, 4 \quad 0, 2 \quad 0, 7 \quad 0, 3]'$ , qual seria seu estimador de  $\alpha$  pela estratégia proposta em (a)?

Resposta:

a)

$$E(X) = \int_0^1 xf(x) dx = (\alpha + 1) \int_0^1 x^{\alpha+1} dx = \left[ \frac{\alpha + 1}{\alpha + 2} x^{\alpha+2} \right]_0^1 = \frac{\alpha + 1}{\alpha + 2}$$

Logo,

$$\begin{aligned} \frac{\hat{\alpha} + 1}{\hat{\alpha} + 2} &= \bar{x} \quad \Longleftrightarrow \quad \hat{\alpha} + 1 = \bar{x}(\hat{\alpha} + 2) \\ (1 - \bar{x})\hat{\alpha} &= 2\bar{x} - 1 \\ \hat{\alpha} &= \frac{2\bar{x} - 1}{1 - \bar{x}} \end{aligned}$$

b)

$$\begin{aligned} X = [0, 1 \quad 0, 4 \quad 0, 2 \quad 0, 7 \quad 0, 3]' &\implies \bar{x} = \frac{17}{50} \\ \hat{\alpha} = \frac{2\bar{x} - 1}{1 - \bar{x}} &= \frac{\frac{34}{50} - 1}{1 - \frac{17}{50}} = -\frac{16}{33} \end{aligned}$$

□

**Exercício 6.** Suponha que  $X \sim N(\mu, \sigma^2)$ , e que você tenha acesso a uma amostra aleatória  $X_1, \dots, X_N$  de realizações de  $X$ . Mostre como sua estimativa de máxima verossimilhança de  $\mu$  depende de  $\sigma$ .

Resposta: Não depende. □

**Exercício 7.** Suponha que  $f(x) = \frac{1}{b}; \quad 0 < X < b$ . Você tem acesso a uma amostra aleatória de tamanho  $N$  de  $X$ .

- a) Obtenha um estimador de máxima verossimilhança para  $b$ .

b) *Obtenha um estimador de método dos momentos para  $b$ .*

Resposta:  $X \sim U[0, b]$

a)

$$f(x) = \frac{1}{b} \mathbb{1}(0, b),$$

em que  $\mathbb{1}$  é uma função indicadora (função lógica que assume valor 1 se argumento é verdadeiro e 0 em caso contrário)

Logo,

$$\mathcal{L}(b) = \left(\frac{1}{b}\right)^N \prod_{i=1}^N \mathbb{1}_{0 \leq X_i \leq b} = \begin{cases} \left(\frac{1}{b}\right)^N, & \text{se } \min\{X_i\} \geq 0 \text{ e } \max\{X_i\} \leq b \\ 0, & \text{caso contrário.} \end{cases}$$

Resposta:  $\hat{b}^{MV} = \max\{X_i\}$ .

Para ver isto, considere inicialmente  $\tilde{b} < \max\{X_i\}$ . Então, para  $x^* \equiv \max\{X_i\}$ , teremos

$$Pr(X = x^* | \tilde{b}) = 0$$

Então,

$$\mathcal{L}(\tilde{b}) = 0,$$

pois basta um elemento do produtório ser nulo para que ele todo seja nulo. Agora, considere  $\tilde{b} > \max\{X_i\}$ . Nesse caso:

$$\mathcal{L}(\tilde{b}) = \frac{1}{\tilde{b}^N} < \frac{1}{\max\{X_i\}^N},$$

pois  $\max\{X_i\}^N < b^N$ .

b)

$$\begin{aligned} f(x) = \frac{1}{b} : \quad 0 < x < b & \implies E(X) = \frac{b}{2} \text{ ou } b = 2E(X) \\ \text{MM : } \hat{b} = 2\bar{X} \end{aligned}$$

□

**Exercício 8.** *(Revisão da aula) Mostre que...*

a) *O erro quadrático médio,  $E[\hat{\theta} - \theta_0]^2$ , equivale à soma da variância e do quadrado do viés, isto é,  $V(\hat{\theta}) + [E(\hat{\theta}) - \theta_0]^2$ .*

b) *Os seguintes testes são assintoticamente equivalentes para  $H_0 : \beta = b$  no contexto de uma estimação por máxima verossimilhança:*

- $w_{LR}(\hat{\theta}) = -\frac{2}{N} \ln \left[ \frac{\mathcal{L}(b)}{\mathcal{L}(\hat{\theta})} \right]$
- $w_{\lambda}(\tilde{\theta}) = \left[ \sqrt{N} \frac{1}{N} S_N(b) \right]' [\mathcal{J}(b)]^{-1} \left[ \sqrt{N} \frac{1}{N} S_N(b) \right] = \lambda' [\mathcal{J}(b)]^{-1} \lambda$
- $w(\hat{\theta}) = \left[ \hat{\theta} - b \right]' \left[ N^{-1} R \mathcal{J}^{-1}(\hat{\theta}) R' \right]^{-1} \left[ \hat{\theta} - b \right]$

Resposta:

a)

$$\begin{aligned} E \left[ (\hat{\theta} - \theta_0)^2 \right] &= E \left[ \left( (\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta_0) \right)^2 \right] \\ &= E \left[ (\hat{\theta} - E(\hat{\theta}))^2 \right] + (E(\hat{\theta}) - \theta_0)^2 + 2E \left( (\hat{\theta} - E(\hat{\theta})) (E(\hat{\theta}) - \theta_0) \right) \end{aligned}$$

Note que  $E(\hat{\theta})$  é constante, pois  $E(a) = a$ . Como  $E(\hat{\theta} - E(\hat{\theta})) = E(\hat{\theta}) - E(\hat{\theta}) = 0$ , então o último termo é igual a zero. Logo,

$$E \left[ (\hat{\theta} - \theta_0)^2 \right] = E \left[ (\hat{\theta} - E(\hat{\theta}))^2 \right] + (E(\hat{\theta}) - \theta_0)^2$$

b) Seja  $\hat{\theta}$  o estimador de MV e  $H_0 : \theta_0 = \tilde{\theta}$

i) Wald:  $w(\hat{\theta}) = (\hat{\theta} - \theta_0)' \mathcal{J}(\theta_0) (\hat{\theta} - \theta_0) \stackrel{A}{\sim} \chi_{(G)}^2$

ii) LR:

$$w_{LR}(\hat{\theta}) = -2 \ln \left[ \frac{\mathcal{L}(\theta_0)}{\mathcal{L}(\hat{\theta})} \right] = -2 \left[ \ell(\theta_0) - \ell(\hat{\theta}) \right]$$

Note que, por expansão de Taylor, temos:

$$\begin{aligned} \frac{1}{N} \ell_N(\hat{\theta}) &\approx \frac{1}{N} \ell_N(\theta_0) + \frac{1}{N} \ell'_N(\theta_0) (\hat{\theta} - \theta_0) + \frac{1}{2} (\hat{\theta} - \theta_0)^\top \frac{1}{N} \ell''_N(\theta_0) (\hat{\theta} - \theta_0) \\ \frac{1}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right] &\approx \frac{1}{N} \ell'_N(\theta_0) (\hat{\theta} - \theta_0) + \frac{1}{2} (\hat{\theta} - \theta_0)^\top \frac{1}{N} \ell''_N(\theta_0) (\hat{\theta} - \theta_0) \end{aligned}$$

Como

$$\frac{1}{N} \ell'_N(\theta_0) (\hat{\theta} - \theta_0) \xrightarrow{P} \cancel{E[S(\theta_0)]}^0 (\hat{\theta} - \theta_0)$$

e

$$\frac{1}{N} \ell''_N(\theta_0) (\hat{\theta} - \theta_0) \xrightarrow{P} \mathcal{J}(\theta_0),$$

então

$$\begin{aligned} \frac{1}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right] &\approx 0 + \frac{1}{2} (\hat{\theta} - \theta_0)^\top \mathcal{J}(\hat{\theta}) (\hat{\theta} - \theta_0) \\ \frac{2}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right] &\approx (\hat{\theta} - \theta_0)^\top \mathcal{J}(\hat{\theta}) (\hat{\theta} - \theta_0) \end{aligned}$$

Como  $-\frac{2}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right] = \frac{2}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right]$ , segue que

$$-\frac{2}{N} \left[ \ell_N(\hat{\theta}) - \ell_N(\theta_0) \right] \approx (\hat{\theta} - \theta_0)^\top \mathcal{J}(\hat{\theta})(\hat{\theta} - \theta_0) = w(\hat{\theta})$$

iii) LM:

$$w_\lambda(\hat{\theta}) = \left[ \sqrt{N} \frac{1}{N} S_N(\hat{\theta}) \right]' \left[ \mathcal{J}(\hat{\theta}) \right]^{-1} \left[ \sqrt{N} \frac{1}{N} S_N(\hat{\theta}) \right]$$

Note que, por expansão de Taylor, temos que

$$\frac{1}{N} S_N(\hat{\theta}) \approx \frac{1}{N} S_N(\theta_0) + \frac{1}{N} S'_N(\theta_0)(\hat{\theta} - \theta_0)$$

Como

$$\frac{1}{N} S_N(\theta_0) \xrightarrow{P} E[S(\theta_0)] = 0$$

e

$$\frac{1}{N} S'_N(\theta_0) \xrightarrow{P} E[S'(\theta_0)] = E[\mathcal{H}_\ell(\theta_0)],$$

então

$$\frac{1}{N} S_N(\hat{\theta}) \approx 0 + E[\mathcal{H}_\ell(\theta_0)](\hat{\theta} - \theta_0)$$

Substituindo em  $w_\lambda(\hat{\theta})$ , segue que

$$\begin{aligned} w_\lambda(\hat{\theta}) &\approx \left[ \sqrt{N} E[\mathcal{H}_\ell(\theta_0)](\hat{\theta} - \theta_0) \right]' \left[ \mathcal{J}(\hat{\theta}) \right]^{-1} \left[ \sqrt{N} E[\mathcal{H}_\ell(\theta_0)](\hat{\theta} - \theta_0) \right] \\ &\approx N \left[ E[\mathcal{H}_\ell(\theta_0)](\hat{\theta} - \theta_0) \right]' \left[ \mathcal{J}(\hat{\theta}) \right]^{-1} \left[ E[\mathcal{H}_\ell(\theta_0)](\hat{\theta} - \theta_0) \right] \end{aligned}$$

Dado que  $E[\mathcal{H}_\ell(\theta_0)] = -\mathcal{J}(\theta_0)$ , temos

$$\begin{aligned} w_\lambda(\hat{\theta}) &\approx N \left[ -\mathcal{J}(\theta_0)(\hat{\theta} - \theta_0) \right]' \left[ \mathcal{J}(\hat{\theta}) \right]^{-1} \left[ -\mathcal{J}(\theta_0)(\hat{\theta} - \theta_0) \right] \\ &\approx N(\hat{\theta} - \theta_0)' \underbrace{[\mathcal{J}(\theta_0)]' \left[ \mathcal{J}(\hat{\theta}) \right]^{-1} \mathcal{J}(\theta_0)}_I (\hat{\theta} - \theta_0) \\ &\approx N(\hat{\theta} - \theta_0)' \mathcal{J}(\theta_0)(\hat{\theta} - \theta_0) = w(\hat{\theta}) \end{aligned}$$

□

**Exercício 9.** Suponha que você tenha acesso a uma amostra de tamanho  $N$  de uma V.A.  $Y$  tal que  $Y_i = \beta + \varepsilon_i$ , onde  $\Pr(\varepsilon = 1) = \Pr(\varepsilon = -1) = \frac{1}{2}$ .

a) Mostre que  $\bar{Y}$  é um estimador não-viesado para  $\beta$ .

b) Suponha que você saiba a priori que  $\beta = 2$  ou  $\beta = 0$ , e queira apenas estimar qual destes dois valores é o verdadeiro. Considere o estimador alternativo:

- $\hat{\beta} = 0$  se ao menos um  $Y_i = -1$
- $\hat{\beta} = 2$  se ao menos um  $Y_i = 3$
- $\hat{\beta} = \bar{Y}$  em caso contrário

Qual estimador é melhor,  $\bar{Y}$  ou  $\hat{\beta}$ ? Por quê?

Resposta:

$$E[\bar{Y}] = E\left[\frac{1}{N} \sum E(Y_i)\right] = \frac{1}{N} \sum E(Y_i) \frac{1}{N} \sum \beta + E(\varepsilon_i) = \beta + \frac{1}{N} \sum E(\varepsilon_i)$$

a)  $E(\varepsilon_i) = \frac{1}{2}(-1) + \frac{1}{2}(1) = 0$

b)  $Y_i$  apenas possui 3 valores:  $\{-1, 1, 3\}$ :

- se  $Y_i = -1 \implies$  para algum  $i$ ,  $\hat{\beta}$  precisa ser 0
- se  $Y_i = 3 \implies$  para algum  $i$ ,  $\hat{\beta}$  precisa ser 2
- se  $Y_i = 1 \implies$  para todo  $i$ ,  $\hat{\beta}$  será  $\bar{Y}$

Portanto,  $\hat{\beta}$  é tão bom quanto  $\bar{Y}$  se  $\bar{Y} = 1$  e é melhor nos demais casos.

□

**Exercício 10.** Suponha que em uma amostra de 21 observações de  $X \sim \exp(\theta)$ , você saiba que a média das 20 primeiras é 6 e que a última é maior do que 15. Como você construiria um estimador de máxima verossimilhança para  $\theta$ ? Qual a resposta para  $\hat{\theta}$ ?

Resposta:

$$\begin{aligned}\mathcal{L}(\theta) &= \prod_{i=1}^{20} \theta e^{-\theta X_i} \cdot \underbrace{(e^{-15\theta})}_{Pr(X > 15)} \\ \ell(\theta) &= \sum_{i=1}^{20} [\ln(\theta) - \theta X_i] - 15\theta \\ &= 20 \ln(\theta) - 20\theta \cdot \frac{1}{20} \sum_{i=1}^{20} X_i - 15\theta \\ &= 20 \ln \theta - 20\theta \cdot 6 - 15\theta = 20 \ln \theta - 135\theta\end{aligned}$$

Maximizando por CPO:

$$\frac{20}{\hat{\theta}} - 135 = 0 \iff \hat{\theta} = \frac{20}{135} = \frac{4}{27}$$

□



**Exercício 11.** Suponha que  $y = a + bx + \varepsilon$ , e que  $E[\varepsilon|X] = 0$ . Mostre que  $\hat{a}^{MQO} = \bar{y} - \frac{\widehat{cov}(y,x)}{\widehat{var}(x)} \bar{x}$  é uma estimativa consistente de  $a$ .

Resposta: Note que  $\hat{a} = \frac{1}{N} \sum_{i=1}^N Y_i - \hat{b} \frac{1}{N} \sum_{i=1}^N X_i$ . Vimos em sala de aula que  $\hat{b} = \frac{\widehat{cov}(y,x)}{\widehat{var}(x)} \xrightarrow{P} b$  e sabemos pela Lei dos Grandes Números que  $\frac{1}{N} \sum_{i=1}^N Y_i \xrightarrow{P} E(Y)$  e que  $\frac{1}{N} \sum_{i=1}^N X_i \xrightarrow{P} E(X)$ . Por Slutsky,  $\hat{a} \xrightarrow{P} E(Y) - bE(X)$ .

Agora, tomando a esperança em  $y = a + bx + \varepsilon$ , segue que:

$$\begin{aligned} E(Y) &= a + bE(X) + E(\varepsilon) \\ E(Y) &= a + bE(X) + 0 & (E(\varepsilon|X) = 0 \implies E(\varepsilon) = 0) \\ a &= E(Y) - bE(X) \end{aligned}$$

Logo,  $\hat{a} \xrightarrow{P} a$ .

□

**Exercício 12.** Uma variável  $X$  tem distribuição normal, mas você não sabe se  $N(1,3)$  ou se  $N(2,3)$ . A partir de uma amostra aleatória com  $N = 10$ , você formula um teste onde  $H_0 : \mu = 1$  e  $H_1 : \mu = 2$ . Pensando em um teste de  $H_0$ :

- Qual o ponto de corte para  $H_0$  coerente com um erro do tipo I de no máximo 10%?
- No caso acima, qual a probabilidade do erro do tipo II?
- Como suas respostas mudam se  $N = 100$ ? Mantendo a probabilidade de erro do tipo I fixa, o que você aprende sobre o comportamento do ponto de corte quando  $N$  aumenta?

Resposta:

- a) Erro do Tipo I =  $Pr(\text{Rejeitar } H_0 | H_0 \text{ verdadeira})$

Sob  $H_0$ :  $\bar{X} \sim N\left(1, \frac{3}{10}\right)$  e  $c^*$  resolve

$$\begin{aligned} Pr[\bar{X} \geq c^*] &\leq 0,1 \\ Pr\left[\frac{\bar{X} - 1}{\sqrt{3/10}} \geq \frac{c^* - 1}{\sqrt{3/10}}\right] &\leq 0,1 \end{aligned}$$

Sejam  $z \equiv \frac{\bar{X} - 1}{\sqrt{3/10}}$  e  $z^* \equiv \frac{c^* - 1}{\sqrt{3/10}}$ , logo

$$Pr[z \geq z^*] \leq 0,1 \implies z^* = 1,28$$

Portanto,

$$z^* = 1,28 \iff \frac{c^* - 1}{\sqrt{3/10}} = 1,28 \iff c^* = 1,70$$

b) Erro do Tipo II =  $Pr(\text{Aceitar } H_0 | H_1 \text{ verdadeira})$

$$Pr \left[ \frac{\bar{x} - 2}{\sqrt{3/10}} \leq \frac{c^* - 2}{\sqrt{3/10}} \right] = Pr[z \leq -0,55] = 0,71$$

c)

$$Pr \left[ z \geq \frac{c^* - 1}{\sqrt{3/100}} \right]$$

Seja  $z^* \equiv \frac{c^* - 1}{\sqrt{3/100}}$ , logo


$$Pr[z \geq z^*] \leq 0,1 \implies z^* = 1,28$$

Portanto,

$$z^* = \frac{c^* - 1}{\sqrt{3/100}} = \frac{10(c^* - 1)}{\sqrt{3}} \implies c^* = 0,22$$

Assim,

$$Pr \left[ z \leq \frac{c^* - 2}{\sqrt{3/100}} \right] = Pr \left[ z \leq \frac{-1,78}{\sqrt{3/100}} \right] = Pr[z \leq -10,28] \approx 0$$



□

**Exercício 13.** A decisão a respeito de publicar um artigo é tipicamente baseada em pareceres de especialistas solicitados pelo editor de uma revista. Em estudo encomendado pela American Economic Association, referente a submissões à American Economic Review, suspeitou-se que as taxas de aceitação de artigos eram maiores quando a submissão não era cega, ou seja, quando os pareceristas sabiam quem estava submetendo o artigo. Neste estudo, um número substancialmente grande de artigos cegos e não-cegos foram aleatoriamente submetidos a diferentes pareceristas para o propósito do estudo. Os dados foram:

Taxas de aceitação (erro padrão estimado entre parênteses)		
Amostra cega	Amostra não-cega	
10,6% (1,1)	14,1% (1,4)	Total
10,0% (3,0)	11,2% (3,5)	Autoras mulheres
11,0% (1,2)	15,0% (1,5)	Autores homens

- a) *A aleatorização foi bem sucedida? Como você testaria o sucesso do procedimento de aleatorização?*
- b) *Teste a hipótese nula de que a submissão ser cega não influencia o resultado de aceitação do artigo.*
- c) *Calcule o p-valor do teste na parte (b)*
- d) *Repita o teste em (b) para as amostras de homens e mulheres separadamente.*
- e) *Existe discriminação contra as mulheres? Construa seu teste de hipótese e apresente suas conclusões.*

Resposta:

- a) Aqui há poucas variáveis para um exercício caprichado, mas um diagnóstico comum é saber se a distribuição de covariadas,  $X$ , é a mesma entre os grupos de tratamento e controle (teste de balanceamento). No caso, a única informação disponível é o gênero do autor. Um possível teste de balanceamento seria calcular a razão homens/mulheres nas duas amostras e testar se são iguais.
- b) Aqui, a nossa V.A.  $X$  para cada submissão é Bernoulli( $p$ ), de modo que

$$Y = \sum_{i=1}^n X_i \quad \text{é Binomial}(n, p)$$

Podemos testar na Binomial, mas como o  $n$  é grande, podemos aproximar em uma Normal:

$$\sum X_i \sim N(np, np(1-p)) \implies \bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

Logo, para a diferença entre as médias temos

$$\bar{X}_A - \bar{X}_B \sim N(p_A - p_B; \sigma_A^2 + \sigma_B^2)$$

Vamos testar na amostra total a hipótese nula de que a média de aceitação entre as amostras cega e não-cega são iguais

$$H_0 : p_A = p_B \sim N(0; 1, 1^2 + 1, 4^2) = N(0; 3, 17)$$

Logo,

$$z = \frac{p_A - p_B}{\sqrt{3,17}} = \frac{10,6 - 14,1}{\sqrt{3,17}} = \frac{3,5}{\sqrt{3,17}} = -1,966$$

Como  $|z| = 1,966 > 1,96$ , então rejeita-se  $H_0$  a 5%.

c) p-valor =  $2 \cdot \Phi(-1,966) = 2 \cdot [1 - \Phi(1,966)] = 0,0493$

d) Mulheres:

$$z = \frac{10 - 11,2}{\sqrt{3^2 + 3,5^2}} = \frac{-1,2}{\sqrt{9 + 12,25}} = -0,26 \implies \text{não rejeita } H_0 \text{ a 5\%}$$

Homens:

$$z = \frac{11 - 15}{\sqrt{1,2^2 + 1,5^2}} = \frac{-4}{\sqrt{3,69}} = -2,08 \implies \text{rejeita } H_0 \text{ a 5\%}$$

e) Os resultados sugerem que apenas os homens melhoram sua taxa de aceitação ao ter seus nomes revelados. Um teste mais caprichado seria comparar os ganhos de ambos:

$$\Delta_h = +4\% \quad \Delta_m = +1,2\% \quad H_0 : \Delta_h = \Delta_m$$

Logo,

$$\Delta_h - \Delta_m \sim N(0; 3^2 + 3,5\% + 1,2^2 + 1,5^2) \approx N(0; 25)$$

Portanto,

$$z = \frac{4 - 1,2}{\sqrt{25}} = \frac{2,8}{5} = 0,56 \implies \text{não rejeita } H_0 \text{ a 5\%}$$

□

**Exercício 14.** Suponha que  $X \sim N(\mu, \sigma^2)$ , e que você tenha acesso a uma amostra aleatória com  $N$  realizações de  $X$ . Considere as seguintes estatísticas:

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i, \quad e \quad X^* = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2$$

a) Mostre que  $\bar{X} \sim N(\mu, \sigma^2/N)$  e  $\frac{NX^*}{\sigma^2} \sim \chi_{N-1}^2$

b) Mostre que  $\bar{X}$  e  $X^*$  são independentes.

Resposta:

[Resultados anteriores:](#)

- Seja  $A$  matriz simétrica com  $N$  autovetores linearmente indep.:

– equação canônica:

$$Av = \lambda v : v \neq \vec{0} \implies AQ = Q\Lambda,$$

em que

$$\Lambda = \begin{bmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_N \end{bmatrix} \quad \text{e} \quad Q = \begin{bmatrix} | & & | \\ v_1 & \dots & v_N \\ | & & | \end{bmatrix},$$

sendo  $Q$  uma matriz ortogonal tal que  $v_i \perp v_j, \forall i \neq j$ . Logo,

$$A = Q\Lambda Q^{-1} \quad \text{e} \quad \Lambda = Q^{-1}AQ$$

– Se  $A$  é simétrica, então  $Q^{-1} = Q^\top \implies M = Q\Lambda Q^\top$

• Para  $M$  idempotente e simétrica (ou seja,  $M^\top = M$  e  $MM = M$ ):

– autovalores de  $M$  são sempre 0 e 1. Faça

$$AAv = A\lambda v \implies Av\lambda Av = \lambda^2 v \implies \lambda v = \lambda^2 v.$$

Como  $v \neq 0$ , então  $\lambda = \lambda^2 \implies \lambda \in \{0, 1\}$

–  $\text{rank}(M) = m = N$ , então

$$\Lambda_{k \times k} = \begin{bmatrix} I_m & 0 \\ 0 & 0 \end{bmatrix}$$

e, sem perda de generalidade, ordene os autovalores por magnitude.

• Se  $Y_p \sim N(0, \sigma^2 I)$ , então  $\frac{Y'Y}{\sigma^2} \sim \chi_{(p)}^2$

– considere  $Q^\top y = v$ , transformação linear de  $y$  tal que

$$* E(v) = 0$$

$$* \text{var}(v) = Q\sigma^2 I Q^\top = \sigma^2 Q Q^\top = \sigma^2 I \quad (Q \text{ ortogonal} \implies Q Q^\top = I)$$

– agora, tome  $\frac{y'My}{\sigma^2} = \frac{v'QMQ'v}{\sigma^2} = \frac{1}{\sigma^2} v' \begin{bmatrix} I_m & 0 \\ 0 & 0 \end{bmatrix} v = \frac{1}{\sigma^2} \sum_{i=1}^m v_i^2 \sim \chi_{(m)}^2$

a) •  $\bar{x} \frac{1}{N} \sum x_i \rightarrow$  Transformação linear de  $\bar{x}$ :

$$\left. \begin{aligned} E(\bar{x}) &= \frac{1}{N} \sum E(x_i) = \frac{N\mu}{N} = \mu \\ V(\bar{x}) &= \frac{1}{N^2} \sum V(x_i) = \frac{N\sigma^2}{N^2} = \frac{\sigma^2}{N} \end{aligned} \right\} \implies \bar{x} \sim N\left(\mu, \frac{\sigma^2}{N}\right)$$

• Defina  $\varepsilon \equiv x - \mu \implies \varepsilon \sim N(0, 1)$  e  $\hat{\varepsilon} \equiv x - \bar{x} \implies M\vec{x} = \hat{\varepsilon}$

•  $x^* = \frac{1}{N} \hat{\varepsilon}' \hat{\varepsilon}$ , como  $\vec{\varepsilon} = \vec{x} - \mu$ , então  $M\vec{\varepsilon} = M\vec{x} - M\mu$ . Note que  $M\mu = 0$ , logo

$$M\vec{\varepsilon} = M\vec{x}$$

$$• x^* = \frac{1}{N} (M\varepsilon)'(M\varepsilon) = \frac{1}{N} \varepsilon' \mu' M \varepsilon = \frac{1}{N} \varepsilon' M M \varepsilon = \frac{1}{N} \varepsilon' M \varepsilon$$

- Usando o resultado anterior:

$$N \frac{x^*}{\sigma^2} = \frac{\varepsilon'}{\sigma} M \frac{\varepsilon}{\sigma} \sim \chi^2_{(\text{rank} M)}$$

$$\begin{aligned} \text{rank}(M) &= \text{Tr}(M) = \text{Tr}(I - \tilde{M}) = \text{Tr}(I) - \text{Tr}(\tilde{M}) \\ &= N - \text{Tr}[\iota(\iota'\iota)^{-1}\iota'] = N - \text{Tr}[(\iota'\iota)^{-1}\iota'\iota] \\ &= N - \text{Tr}(1) = N - 1 \end{aligned}$$

b) Primeiro, lembre que, para  $\vec{x}$  normal, temos que  $\text{cor}(x_i, x_j) = 0$  implica independência.

Sejam  $x_1 = \bar{x} = \frac{1}{N} \sum x$  e  $x_2 = \hat{\varepsilon}_i = x_i - \bar{x}$  para qualquer  $i$ . Segue que

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \sim N \left( \begin{bmatrix} \mu \\ 0 \end{bmatrix}; \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{N-1}{N}\sigma^2 \end{bmatrix} \right)$$

Logo,

$$x^* = \frac{\sum \hat{\varepsilon}^2}{N} = g(\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_N).$$

Se todo  $\hat{\varepsilon} \perp \bar{x}$ , então

$$g(\hat{\varepsilon}_1, \dots, \hat{\varepsilon}_N) \perp \bar{x}.$$

□

**Exercício 15.** Considere o modelo  $y = bx + \varepsilon$ . Suponha que  $E(\varepsilon) = 0$  e  $E(\varepsilon x) = 0$ .

- Construa um estimador de método dos momentos para  $b$  que utilize  $E(\varepsilon) = 0$ .
- Construa um estimador de método dos momentos para  $b$  que utilize  $E(\varepsilon x) = 0$ .
- Se  $\varepsilon|X \sim N(0, \sigma^2)$ , qual dos dois estimadores é melhor? Justifique.

Resposta:

$$y = bx + \varepsilon \implies \varepsilon = y - bx$$

a)

$$E(\varepsilon) = 0 \implies \frac{1}{N} \sum y_i - \hat{b}x_i = 0 \implies \hat{b}_1 = \frac{\bar{y}}{\bar{x}}$$

b)

$$E(\varepsilon x) = 0 \implies \frac{1}{N} \sum (y_i - \hat{b}x_i)x_i = 0 \implies \hat{b}_2 = \frac{\sum y_i x_i}{\sum x_i^2}$$

c) Para  $\hat{b}_1$ :

$$\hat{b}_1 = \frac{1}{N} \sum \left( \frac{y_i}{\bar{x}} \right) = \frac{1}{N} \sum \frac{bx_i + \varepsilon_i}{\bar{x}} = b + \frac{\bar{\varepsilon}}{\bar{x}}$$

Se  $\varepsilon|X \sim N(0, \sigma^2)$ , então  $E(\hat{b}_1) = b$  e

$$Var(\hat{b}_1) = Var\left(\frac{\bar{\varepsilon}}{\bar{x}}\right) = E\left[Var(\hat{b}_1|\bar{x})\right] = E\left[\frac{\sigma^2}{N\bar{x}^2}\right]$$

Para  $\hat{b}_2$ :

$$\hat{b}_2 = \frac{\sum y_i x_i}{\sum x_i^2} = \frac{\sum (bx_i + \varepsilon)x_i}{\sum x_i^2} = \frac{\sum bx_i^2}{\sum x_i^2} + \frac{\sum \varepsilon x_i}{\sum x_i^2} = b + \frac{\sum \varepsilon x_i}{\sum x_i^2}$$

Logo,

$$\begin{aligned} E(\hat{b}_2) &= E\left(b + \frac{\sum \varepsilon_i x_i}{\sum x_i^2}\right) = b \\ Var(\hat{b}_2) &= Var\left(\frac{\sum \varepsilon_i x_i}{\sum x_i^2}\right) = E\left[Var\left(\frac{\sum \varepsilon_i x_i}{\sum x_i^2} \middle| x\right)\right] \\ &= E\left[\frac{1}{(\sum x_i^2)^2} \sigma^2 \sum x_i^2\right] = E\left[\frac{\sigma^2}{\sum x_i^2}\right] \\ &= E\left[\frac{\sigma^2}{N(\widehat{var}(x) + \bar{x}^2)}\right] < E\left[\frac{\sigma^2}{N\bar{x}^2}\right] = Var(\hat{b}_1) \end{aligned}$$

Portanto, ambos estimadores são não-viesados ( $\hat{b}_1 = \hat{b}_2 = b$ ), mas  $Var(\hat{b}_2) < Var(\hat{b}_1)$ .

□

**Exercício 16.** Sejam  $\beta_0^{MQO}$ ,  $\beta_1^{MQO}$  o intercepto e inclinação de uma estimação por MQO do modelo  $y = \beta_0 + \beta_0 x + \varepsilon$ , em amostra de tamanho  $N$ . Para constantes não-nulas  $c_1, c_2$ , construa novas variáveis  $\tilde{y} = c_1 y$  e  $\tilde{x} = c_2 x$ .

- a) Sejam  $\tilde{\beta}_0, \tilde{\beta}_1$  o intercepto e inclinação de uma regressão por MQO de  $\tilde{y}$  em  $\tilde{x}$ . Mostre que  $\tilde{\beta}_1 = \frac{c_1}{c_2} \beta_1^{MQO}$  e  $\tilde{\beta}_0 = c_1 \beta_0^{MQO}$
- b) Agora, sejam  $\tilde{\beta}_0, \tilde{\beta}_1$  o intercepto e inclinação de uma regressão por MQO de  $c_1 + y$  em  $c_2 + x$ . Mostre que  $\tilde{\beta}_1 = \beta_1^{MQO}$  e  $\tilde{\beta}_0 = \beta_0^{MQO} + c_1 - c_2 \beta_1^{MQO}$

Resposta:

a)

$$\begin{aligned} \tilde{\beta}_0 &= \bar{\tilde{y}} - \tilde{\beta}_1 \bar{\tilde{x}} \\ \tilde{\beta}_1 &= \frac{\widehat{cov}(\tilde{x}, \tilde{y})}{\widehat{var}(\tilde{x})} = \frac{\widehat{cov}(c_2 x, c_1 y)}{\widehat{var}(c_2 x)} = \frac{c_2 c_1}{c_2^2} \frac{\widehat{cov}(x, y)}{\widehat{var}(x)} = \frac{c_1}{c_2} \beta_1^{MQO} \end{aligned}$$

Substituindo  $\tilde{\beta}_1$  em  $\tilde{\beta}_0$ , segue que

$$\tilde{\beta}_0 = \bar{\tilde{y}} - \tilde{\beta}_1 \bar{\tilde{x}} = c_1 \bar{y} - \frac{c_1}{c_2} \hat{\beta}_1^{MQO} c_2 \bar{x} = c_1 \left[ \bar{y} - \hat{\beta}_1^{MQO} \bar{x} \right] = c_1 \hat{\beta}_0^{MQO}$$

b)

$$\tilde{\beta}_1 = \frac{\widehat{cov}(\check{x}, \check{y})}{\widehat{var}(\check{x})} = \frac{\widehat{cov}(c_2 + x, c_1 + y)}{\widehat{var}(c_2 + x)} \stackrel{(a)}{=} \frac{\widehat{cov}(x, y)}{\widehat{var}(x)} = \hat{\beta}_1^{MQO}$$

(a): somar constantes não altera os segundos momentos

Substituindo  $\tilde{\beta}_1$  em  $\tilde{\beta}_0$ , segue que

$$\begin{aligned}\tilde{\beta}_0 &= \bar{\check{y}} - \tilde{\beta}_1 \bar{\check{x}} = (\overline{c_1 + y}) - \tilde{\beta}_1 (\overline{c_2 + x}) = (\overline{c_1 + y}) - \tilde{\beta}_1^{MQO} (\overline{c_2 + x}) \\ &= \left( \bar{y} - \hat{\beta}_1^{MQO} \bar{x} \right) + c_1 - c_2 \hat{\beta}_1^{MQO} = \hat{\beta}_0^{MQO} + c_1 - c_2 \hat{\beta}_1^{MQO}\end{aligned}$$

□