

Lista 3

Exercício 1. Suponha que $y = a + bx + \varepsilon$ satisfaça as hipóteses de Gauss-Markov. Você tem uma amostra de 500 indivíduos e sabe que

$$\sum X_i = 3000, \quad \sum Y_i = 1400, \quad \sum X_i Y_i = 18000, \quad \sum X_i^2 = 66000, \quad e \quad \sum Y_i^2 = 7200$$

a) Ache b^{MQO}

b) Você é capaz de obter o R^2 nesse caso? E o S^2 ?

c) Como você testaria $H_0 : b < 0,5$?

Resposta:

a) Note que

$$\hat{\beta} = (X'X)^{-1}X'Y \quad ; \quad X = \begin{bmatrix} 1 & X_1 \\ \vdots & \vdots \\ 1 & X_N \end{bmatrix} \quad \Rightarrow \quad X'X = \begin{bmatrix} N & \sum X_i \\ \sum X_i & \sum X_i^2 \end{bmatrix}$$

$$\begin{aligned} (X'X)^{-1} &= \frac{1}{N \sum X_i^2 - (\sum X_i)^2} \begin{bmatrix} \sum X_i^2 & -\sum X_i \\ -\sum X_i & N \end{bmatrix} \\ &= \frac{1}{500 \cdot 66000 - (3000)^2} \begin{bmatrix} 66000 & -3000 \\ -3000 & 500 \end{bmatrix} \\ X'Y &= \begin{bmatrix} \sum Y_i \\ \sum X_i Y_i \end{bmatrix} = \begin{bmatrix} 1400 \\ 18000 \end{bmatrix} \end{aligned}$$

Logo,

$$\hat{\beta} = \begin{bmatrix} 1,60 \\ 0,20 \end{bmatrix}$$

b)

$$\begin{aligned} \hat{V}(Y) &= \frac{7200}{500} - \left(\frac{1400}{500} \right)^2 = 14,4 - 7,84 = 6,56 \\ \hat{V}(\hat{Y}) &= \hat{\beta}^2 \hat{V}(X) = 0,2^2 \left[\frac{66000}{500} - \left(\frac{3000}{500} \right)^2 \right] = 3,84 \end{aligned}$$

Logo,

$$R^2 = \frac{\hat{V}(\hat{Y})}{\hat{V}(Y)} = \frac{3,84}{6,56} = 0,5854$$

$$\begin{aligned}\hat{V}(Y) &= \hat{V}(\hat{Y}) + \hat{V}(\hat{\varepsilon}) \\ \hat{V}(\hat{\varepsilon}) &= \hat{\sigma}^2 = 6,56 - 3,84 = 2,72\end{aligned}$$

Então,

$$S^2 = \frac{N}{N-2} \hat{\sigma}^2 = \frac{500}{498} 2,72 = 2,73$$

c) (estou vendo a resposta com o professor)

□

Exercício 2. Suponha que um pesquisador regrida a nota média de uma amostra de 100 salas de aula de 9º ano contra o tamanho da sala. O resultado foi

$$Y = \underset{(20,4)}{520,4} - \underset{(2,21)}{5,82}T + \varepsilon,$$

onde em parênteses há o erro padrão. A média do tamanho de turma é 21,4 e $S^2 = 1$. Você sabe ainda que $\sum X_i^2 = 215$.

- Se uma sala tem 22 estudantes, qual sua predição para a nota média da turma? Qual o intervalo de confiança (95%) em torno dessa predição?
- Construa um intervalo de confiança de 95% para b_1 , a inclinação de sua reta de regressão.
- Calcule o p-valor para um teste de $H_0 : b_1 = 0$. Você rejeita a nula a 5%? A 1%?
- Qual a média de Y ?

Resposta:

- a) Valor predito para turma com $T = 22$ alunos:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot T = 520,4 - 5,82 \cdot 22 = 329,36$$

Intervalo de confiança:

$$\begin{aligned}IC_{95\%} &= \hat{Y} \pm t_{(98)}^{95\%} \sqrt{S^2} \sqrt{\frac{1}{N} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}} \\ &= 329,36 \pm 1,98 \left(1 \sqrt{\frac{1}{100} + \frac{0,6^2}{1}} \right) \\ &= [328,16 ; 330,56]\end{aligned}$$

b)

$$\frac{\hat{\beta}_1 - \beta_1}{S_{b_1}} \sim t_{N-2}$$

Então,

$$IC_{5\%} = \hat{\beta}_1 \pm t_{(N-2; 97,5\%)} \cdot S_{b_1} = [-10,24 ; -1,4]$$

c)

$$t^* = \frac{\hat{\beta}_1}{S_{b_1}} = \frac{-5,82}{2,21} = -2,633$$

Logo,

$$Pr(\tau_{98} < -2,633) = 0,016 \implies \text{p-valor} = \frac{0,016}{2} = 0,008$$

Então, rejeitamos $H_0 : \beta_1 = 0$ para $\alpha = 0,05$ e $\alpha = 0,01$.

d) Note que $\bar{T} = 21,4$, pois sabemos que $\hat{Y}(\bar{T}) = \bar{Y}$ (a reta de regressão passa por \bar{Y}, \bar{T}).
Portanto,

$$\bar{Y} = \hat{Y}(\bar{T}) = 520,4 - 5,82 \times 21,4 = 395,85$$

□

Exercício 3. Considere o modelo $\mathbf{y}_i = \mathbf{x}'_{1i}\boldsymbol{\beta} + \mathbf{x}'_{2i}\boldsymbol{\gamma} + \varepsilon_i$, onde \mathbf{x}_1 é um vetor contendo K elementos, \mathbf{x}_2 contém M elementos, e todas as variáveis já estão em desvios com respeito à média (por exemplo, $y_i = y_{0i} - \bar{y}_0$, para alguma variável primária y_0), de modo que o modelo não contém intercepto. Suponha que $E[\varepsilon|x_1, x_2] = 0$, e que $E[\varepsilon^2|x_1, x_2] = \sigma^2 I$.

- a) Suponha que $\mathbf{x}'_1 \mathbf{x}'_2 = 0$. Mostre que nesse caso os estimadores $\hat{\boldsymbol{\beta}} = (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{y}$, e $\hat{\boldsymbol{\gamma}} = (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{y}$ são ambos os melhores estimadores lineares não-viesados para $(\boldsymbol{\beta}, \boldsymbol{\gamma})$.
- b) Caso $\mathbf{x}'_1 \mathbf{x}_2 \neq 0$, sua resposta acima se mantém? Justifique e caracterize os respectivos vieses caso os encontre.
- c) Novamente suponha que $\mathbf{x}'_1 \mathbf{x}_2 \neq 0$. Seja $\mathbf{M}_2 = \mathbf{I} - \mathbf{x}_2(\mathbf{x}'_2 \mathbf{x}_2)^{-1} \mathbf{x}'_2$. Qual a interpretação para \mathbf{M}_2 ? Mostre que sua estimativa de MQO para β_1 pode ser escrita como: $\beta_1 = (\mathbf{X}'_1 \mathbf{M}_2 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{M}_2 \mathbf{y}$. Compute a matriz de variâncias e covariâncias de $\hat{\beta}_1$.
- d) Ainda no caso anterior, e particularizando para o caso onde x_1 e x_2 contenham apenas uma variável cada, expresse a variância de $\hat{\beta}_1$ como função da correlação entre x_1 e x_2 , r_{12} . O que acontece quando $r_{12} \rightarrow 1$?

Resposta: Sejam:

$$X'X = \begin{bmatrix} x'_1 x_1 & x'_1 x_2 \\ x'_2 x_1 & x'_2 x_2 \end{bmatrix} \quad \text{e} \quad \hat{\boldsymbol{\theta}} = \begin{bmatrix} \hat{\beta} \\ \hat{\gamma} \end{bmatrix}$$

Na derivação de MQO, vimos que

$$(X'X)\hat{\boldsymbol{\theta}} = X'y$$

$$\begin{bmatrix} x'_1 x_1 & x'_1 x_2 \\ x'_2 x_1 & x'_2 x_2 \end{bmatrix} \begin{bmatrix} \hat{\beta} \\ \hat{\gamma} \end{bmatrix} = \begin{bmatrix} x'_1 y \\ x'_2 y \end{bmatrix}$$

que pode ser reescrito como

$$\begin{cases} x'_1 x_1 \hat{\beta} + x'_1 x_2 \hat{\gamma} = x'_1 y \\ x'_2 x_1 \hat{\beta} + x'_2 x_2 \hat{\gamma} = x'_2 y \end{cases} \quad (*)$$

Resolvendo para $\hat{\beta}$ segue que

$$\hat{\beta} = (x'_1 x_1)^{-1} x'_1 y - (x'_1 x_1)^{-1} x'_1 x_2 \hat{\gamma}$$

- a) $x'_1 x'_2 = 0 \implies \hat{\beta} = (x'_1 x_1) x'_1 y$. Como temos, pelo enunciado, o ambiente de Gauss-Markov satisfeito, então $\hat{\theta}' = [\hat{\beta} \quad \hat{\gamma}]$ é BLUE.

Sob $X'X = 0$, $\tilde{\beta} = \hat{\beta} \implies \tilde{\beta}$ é BLUE (para $\hat{\gamma}$, a demonstração é igual)

- b) Usando (*) temos:

$$\begin{cases} \hat{\beta} = (x'_1 x_1)^{-1} x'_1 y - (x'_1 x_1)^{-1} x'_1 x_2 \hat{\gamma} \\ \hat{\gamma} = (x'_2 x_2)^{-1} x'_2 y - (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta} \end{cases}$$

Logo,

$$\begin{aligned} \hat{\beta} &= (x'_1 x_1)^{-1} x'_1 y - (x'_1 x_1)^{-1} x'_1 x_2 \cdot [(x'_2 x_2)^{-1} x'_2 y - (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta}] \\ &= [(x'_1 x_1)^{-1} x'_1 - (x'_1 x_1)^{-1} x'_1 x_2 (x'_2 x_2)^{-1} x'_2] y + (x'_1 x_1)^{-1} x'_1 x_2 (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta} \\ \hat{\beta} - (x'_1 x_1)^{-1} x'_1 x_2 (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta} &= (x'_1 x_1)^{-1} x'_1 [I - x_2 (x'_2 x_2)^{-1} x'_2] y \\ (\mathbf{x}'_1 \mathbf{x}_1) [\hat{\beta} - (x'_1 x_1)^{-1} x'_1 x_2 (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta}] &= (\mathbf{x}'_1 \mathbf{x}_1) (x'_1 x_1)^{-1} x'_1 [I - x_2 (x'_2 x_2)^{-1} x'_2] y \\ x'_1 x_1 \hat{\beta} - x'_1 x_2 (x'_2 x_2)^{-1} x'_2 x_1 \hat{\beta} &= x'_1 [I - x_2 (x'_2 x_2)^{-1} x'_2] y \\ x'_1 [I - x_2 (x'_2 x_2)^{-1} x'_2] x_1 \hat{\beta} &= x'_1 [I - x_2 (x'_2 x_2)^{-1} x'_2] y \\ x'_1 M_2 x_1 \hat{\beta} &= x'_1 M_2 y \\ \hat{\beta} &= (x'_1 M_2 x_1)^{-1} x'_1 M_2 y, \end{aligned}$$

em que $M_2 = I - x_2 (x'_2 x_2)^{-1} x'_2$ é a matriz de projeção no núcleo do espaço-coluna de X_2 . Perceba, portanto, que $\hat{\beta}^{MQO}$ explora a variação em X_1 após a remoção da variação em X_2 .

Seja $\tilde{x}_1 \equiv M_2 x_1$ e $\tilde{y} \equiv M_2 y$, então $\hat{\beta}^{MQO} = (\tilde{x}'_1 \tilde{x}_1)^{-1} \tilde{x}'_1 \tilde{y}$.

Logo,

$$\begin{aligned} \hat{\beta} &= (x'_1 M_2 x_1)^{-1} x'_1 M_2 y = \tilde{\beta} - (x'_1 x_1)^{-1} x'_1 x_2 \hat{\gamma} \\ \tilde{\beta} &= (x'_1 x_1)^{-1} x'_1 y \end{aligned}$$

Como inicialmente Gauss-Markov é satisfeito, temos $E(\hat{\beta}) = \beta$ e $E(\hat{\gamma}) = \gamma$. Logo,

$$E(\tilde{\beta}|X) = \beta + (x'_1 x_1)^{-1} x'_1 x_2 \gamma$$

em que $(x'_1 x_1)^{-1} x'_1 x_2 \gamma$ é o viés de variável omitida.

- c) $cov(\hat{\beta}) = cov[(x'_1 M_2 x_1)^{-1} x'_1 M_2 \varepsilon] = \sigma^2 (x'_1 M_2 x_1)^{-1}$

- d)

$$\begin{aligned} V(\hat{\beta}) &= \sigma^2 \left[x'_1 x_1 - \frac{(x'_1 x_2)^2}{x'_2 x_2} \right]^{-1} \\ &= \sigma^2 \left[x'_1 x_1 \left(1 - \frac{(x'_1 x_2)^2}{(x'_1 x_1)(x'_2 x_2)} \right) \right]^{-1} \\ &= \sigma^2 (x'_1 x_1)^{-1} (1 - \rho_{12}^2)^{-1} \\ &= \frac{\sigma^2}{NV(x_1)(1 - \rho_{12}^2)} \end{aligned}$$

Logo,

$$\hat{V}(\hat{\beta}) = \frac{\hat{\sigma}^2}{N\hat{V}(x_1)(1 - r_{12}^2)} \quad \text{e} \quad \lim_{|\rho_{12}| \rightarrow 1} V(\hat{\beta}) = +\infty$$

□

Exercício 4. Suponha que seu modelo verdadeiro seja $\mathbf{y}_i = \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i$. No entanto, o economista estimou $\mathbf{y}_i = \mathbf{x}_i'\boldsymbol{\beta} + \mathbf{z}_i'\boldsymbol{\gamma} + \boldsymbol{\varepsilon}_i$. Sejam $\hat{\boldsymbol{\beta}}$ e $\tilde{\boldsymbol{\beta}}$ os estimadores de MQO para $\boldsymbol{\beta}$ no modelo correto e modelo mal especificado, respectivamente. Considere ainda que $E[\boldsymbol{\varepsilon}|\mathbf{X}, \mathbf{Z}] = 0$ e $E[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'|\mathbf{X}, \mathbf{Z}] = \sigma^2\mathbf{I}$.

- $\tilde{\boldsymbol{\beta}}$ é viesado? Justifique
- Compute a matriz de variâncias e covariâncias para $[\tilde{\boldsymbol{\beta}} \quad \tilde{\boldsymbol{\gamma}}]'$. Compare o bloco correspondente a $\tilde{\boldsymbol{\beta}}$ com matriz de variâncias e covariâncias de $\hat{\boldsymbol{\beta}}$. Quando elas são idênticas?
- Se você souber apenas que $E[\boldsymbol{\varepsilon}|\mathbf{X}] = 0$, como sua resposta (a) se altera?

Resposta:

- Retornando ao raciocínio do exercício anterior:

$$\begin{aligned} \tilde{\boldsymbol{\beta}} &= \boldsymbol{\beta} + (x'M_zx)^{-1}x'M_z\varepsilon \\ E(\tilde{\boldsymbol{\beta}}) &= E_{X,Z} \left[E(\tilde{\boldsymbol{\beta}}|X, Z) \right] \\ &= \boldsymbol{\beta} + E_{X,Z} \left[E \left((x'M_zx)^{-1}x'M_z\varepsilon \right) \right] \\ &= \boldsymbol{\beta} + E_{X,Z} \left[(x'M_zx)^{-1}x'M_z \underbrace{E(\varepsilon|X, Z)}_{\rightarrow 0} \right] = \boldsymbol{\beta} \end{aligned}$$

Estimador é não-viesado.

- $\hat{\boldsymbol{\beta}}$ é mais eficiente do que $\tilde{\boldsymbol{\beta}}$ se e somente se $V(\tilde{\boldsymbol{\beta}}) - V(\hat{\boldsymbol{\beta}})$ for positiva-definida
 $\iff \sigma^{-2}[V(\tilde{\boldsymbol{\beta}}) - V(\hat{\boldsymbol{\beta}})]$ positiva-definida $\iff (x'M_zx)^{-1} - (x'x)^{-1}$ for positiva-definida

$$\begin{aligned} V(\hat{\boldsymbol{\beta}}) &= \sigma^2(x'x)^{-1} \\ V(\tilde{\boldsymbol{\beta}}) &= \sigma^2(x'M_zx)^{-1} \\ &= \sigma^2(x'(I - P_z)x)^{-1} \\ &= \sigma^2(x'x - x'P_zx)^{-1} \end{aligned}$$

Lema: A positiva-definida $\implies C'AC$ positiva-definida, em que C tem posto completo

Prova: $x'Ax > 0$ para todo x não-nulo. Seja $Cx = x$. Logo, $V'C'ACV$ para todo V não-nulo $\implies C'AC$ positiva-definida.

Lema: $A - B$ positiva-definida $\implies C'(A - B)C$ positiva-definida

Lema: $B - I$ positiva-definida e B positiva-definida $\implies I - B^{-1}$ positiva-definida

Prova: $B = C\Lambda C'$; $CC' = I$; $C' = C^{-1}$; $B - I = C(\Lambda - I)C'$;
 $B^{-1} = C'^{-1}\Lambda^{-1}C^{-1}$; $I = CC' = (C^{-1})'C^{-1}$

Como $\Lambda - I$ é positiva-definida, todos os auto-valores λ de Λ são maiores que 1, caso contrário haveria algum $V \neq 0$ para o qual $V'(\Lambda - I)V < 0$

$$\Lambda^{-1} = \begin{bmatrix} \lambda_1^{-1} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_N^{-1} \end{bmatrix} \implies \lambda_i^{-1} < 1, \forall i$$

$$\implies I - \Lambda \text{ positiva-definida} \implies I - B^{-1} \text{ idem.}$$

Proposição: $B - A$ positiva-definida $\implies A^{-1} - B^{-1}$ positiva-definida.

Prova:

$$\begin{aligned} B - A \text{ pos-def} &\implies A^{-1/2}(B - A)(A^{-1/2})' \text{ pos-def} \\ &\implies A^{-1/2}B(A^{-1/2})' - A^{-1/2}A^{1/2}(A^{1/2})'(A^{-1/2})' \text{ pos-def} \\ &\implies A^{-1/2}B(A^{-1/2})' - I \text{ pos-def} \\ &\implies I - [A^{-1/2}B(A^{-1/2})']^{-1} \text{ pos-def} \\ &\implies I - (A^{1/2})'B^{-1}A^{1/2} \text{ pos-def} \\ &\implies (A^{1/2})'[(A^{1/2})']^{-1}(A^{1/2})^{-1}A^{-1/2} - (A^{1/2})'B^{-1}A^{1/2} \text{ pos-def} \\ &\implies (A^{1/2})'([(A^{1/2})']^{-1}(A^{1/2})^{-1} - B^{-1})A^{1/2} \text{ pos-def} \\ &\implies (A^{1/2})'(A^{-1} - B^{-1})A^{1/2} \text{ pos-def} \\ &\implies [(A^{1/2})']^{-1}(A^{1/2})'(A^{-1} - B^{-1})A^{1/2}(A^{1/2})^{-1} \text{ pos-def} \\ &\implies A^{-1} - B^{-1} \text{ pos-def} \end{aligned}$$

Finalmente,

$$\begin{aligned} V(\hat{\beta}) < V(\tilde{\beta}) &\iff \sigma^2(x'x)^{-1} < \sigma^2(x'M_zx)^{-1} \\ &\iff (x'x)^{-1} < (x'M_zx)^{-1} \\ &\iff x'x < x'M_zx = x'(I - P_z)x \\ &\iff x'x < x'x - x'P_zx \\ &\iff -x'P_zx < 0 \\ &\iff x'P_zx \geq 0 \\ &\iff P_z \geq 0 \quad (\text{verdade, pois } P_z \text{ é positiva-semidefinida}) \end{aligned}$$

c) $\tilde{\beta} = \beta + (x'M_zx)^{-1}x'M_z\varepsilon$, em que

- $E[(x'M_zx)^{-1}x'M_z\varepsilon] = \text{viés}$
- $M_z = I - P_z \implies \text{viés} = 0$, caso $P_zX = 0$.

□

Exercício 5. Suponha que $y = a + bx + \varepsilon$. Você tem uma base de dados com duas colunas para x , uma onde essa variável é medida em unidades e outra onde é medida em dezenas. Você experimenta estimar seu modelo com ambas as variáveis.

- a) Como os valores obtidos para R^2 , S^2 , \hat{b} , \hat{a} se comparam nos dois exercícios?
- b) Como as estatísticas de teste para a hipótese $H_0 : b = 0$ se comparam entre os dois exercícios?
- c) Como o p -valor de \hat{b} e o intervalo de confiança de 95% para b se comparam entre os dois exercícios?

Resposta:

- a) Seja $x_1 = 10x_0$, então

$$\begin{aligned}\hat{b}_0 &= \frac{\widehat{cov}(y, x_0)}{\widehat{V}(x_0)} \\ \hat{b}_1 &= \frac{\widehat{cov}(y, 10x_0)}{\widehat{V}(10x_0)} = \frac{10\widehat{cov}(y, x_0)}{10^2\widehat{V}(x_0)} = \frac{\hat{b}_0}{10}\end{aligned}\tag{1}$$

$$\hat{a}_1 = \bar{y} - \hat{b}_1\bar{x}_1 = \bar{y} - \frac{\hat{b}_0}{10}10\bar{x}_0 = \bar{y} - \hat{b}_0\bar{x}_0 = \hat{a}_0\tag{2}$$

Para todo i :

$$\begin{aligned}\hat{\varepsilon}_{1i} &= y_i - \hat{a}_1 - \hat{b}_1x_{1i} \\ &= y_i - \hat{a}_0 - \frac{\hat{b}_0}{10}10x_{0i} \quad (\text{por 1 e 2}) \\ &= y_i - \hat{a}_0 - \hat{b}_0x_{0i} \\ &= \hat{\varepsilon}_{0i}\end{aligned}\tag{3}$$

Logo, usando (3),

$$\begin{aligned}S_1^2 &= \frac{1}{N-2} \sum_{i=1}^N \varepsilon_{1i}^2 = \frac{1}{N-2} \sum_{i=1}^N \varepsilon_{0i}^2 = S_0^2 \\ R_1^2 &= 1 - \frac{\sum_{i=1}^N \varepsilon_{1i}^2}{SQT} = 1 - \frac{\sum_{i=1}^N \varepsilon_{0i}^2}{SQT} = R_0^2\end{aligned}$$

- b)

$$\begin{aligned}var(\hat{b}_1) &= \frac{\sigma^2}{\sum_{i=1}^N (x_{1i} - \bar{x}_1)^2} = \frac{\sigma^2}{\sum_{i=1}^N (10x_{0i} - 10\bar{x}_0)^2} = \frac{\sigma^2}{10^2 \sum_{i=1}^N (x_{0i} - \bar{x}_0)^2} = \frac{1}{10^2} var(\hat{b}_0) \\ SD(\hat{b}_1) &= \frac{1}{10} SD(\hat{b}_0) \\ t_1 &= \frac{\hat{b}_1}{SD(\hat{b}_1)} = \frac{\hat{b}_0/10}{SD(\hat{b}_0)/10} = \frac{\hat{b}_0}{SD(\hat{b}_0)} = t_0\end{aligned}$$

c)

$$\begin{aligned} IC_1^{95\%} &= [\hat{b}_1 \pm 1, 96.SD(\hat{b}_1)] = \left[\frac{\hat{b}_0}{10} \pm 1, 96.\frac{SD(\hat{b}_0)}{10} \right] \\ &= \frac{1}{10} [\hat{b}_0 \pm 1, 96.SD(\hat{b}_0)] = \frac{1}{10} IC_0^{95\%} \end{aligned}$$

$$\tau_1 = \frac{\hat{b}_1}{SD(\hat{b}_1)} = \frac{\hat{b}_0/10}{SD(\hat{b}_0)/10} = \frac{\hat{b}_0}{SD(\hat{b}_0)} = \tau_0 \sim t_{N-2}$$

Logo, $Pr[\tau_0 < T] = Pr[\tau_1 < T], \forall T$:

$$\implies \begin{cases} Pr(T \geq \tau_0 | H_0) = Pr(T \geq \tau_1 | H_0) \\ Pr(T \leq \tau_0 | H_0) = Pr(T \leq \tau_1 | H_0) \end{cases} \quad (\text{unicaudal})$$

ou

$$\implies \begin{cases} 2 \times \min [Pr(T \geq \tau_0 | H_0); Pr(T \leq \tau_0 | H_0)] \\ 2 \times \min [Pr(T \geq \tau_1 | H_0); Pr(T \leq \tau_1 | H_0)] \end{cases} \quad (\text{bicaudal})$$

□

Exercício 6. Considere os seguintes modelos:

$$y_i = a + bx_i + \epsilon_i \quad (1)$$

$$x_i = \alpha + \beta y_i + \epsilon_i \quad (2)$$

a) Compare b^{MQO} e β^{MQO} . O que ocorre se y e x possuírem variância (amostral) unitária nesse caso? Se o sinal de b^{MQO} for positivo, o que você aprende sobre o sinal de β^{MQO} ?

b) Compare o R^2 dos dois exercícios.

Resposta:

a)

$$\hat{b} = \frac{\widehat{cov}(X, Y)}{\widehat{V}(X)}; \quad \hat{\beta} = \frac{\widehat{cov}(X, Y)}{\widehat{V}(Y)} \implies \hat{b}\hat{\beta} = \frac{\widehat{cov}^2(X, Y)}{\widehat{V}(X)\widehat{V}(Y)} = \hat{\rho}_{XY}^2$$

em que

$$0 \leq \hat{b}\hat{\beta} \leq 1 \implies |\hat{b}| \leq \frac{1}{|\hat{\beta}|}.$$

Além disso:

$$\text{sign}(\hat{b}) = \text{sign}(\widehat{cov}(X, Y)) = \text{sign}(\hat{\beta})$$

Se $\widehat{V}(X) = \widehat{V}(Y) = 1$, então $\hat{b} = \hat{\beta}$.

b)

$$\begin{aligned} R_1^2 &= \frac{SQE}{SQT} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^N (y_i - \bar{y})^2} = \frac{\sum_{i=1}^N [\hat{a} + \hat{b}x_i - \hat{a} - \hat{b}\bar{x}]^2}{\sum_{i=1}^N (y_i - \bar{y})^2} = \hat{b}^2 \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \\ &= \frac{\widehat{cov}^2(X, Y)}{\widehat{V}^2(X)} \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{\sum_{i=1}^N (y_i - \bar{y})^2} = \frac{\widehat{cov}^2(X, Y)}{\widehat{V}^2(X)} \frac{\widehat{V}(X)}{\widehat{V}(Y)} = \frac{\widehat{cov}^2(X, Y)}{\widehat{V}(X)\widehat{V}(Y)} \end{aligned}$$

Analogamente,

$$R_2^2 = \frac{\widehat{cov}^2(X, Y)}{\widehat{V}(X)\widehat{V}(Y)} = R_1^2$$

□

Exercício 7. Suponha que o modelo verdadeiro seja $y = \alpha + \beta \ln(x) + \varepsilon$, e que $E[\varepsilon|x] = 0$. No entanto, você erroneamente estimou $y = a + bx + u$.

a) $E[u|x] = 0$? Justifique

b) b^{MQO} é consistente? Justifique.

Resposta:

a)

$$\begin{aligned} u &= y - a - bx = (\alpha + \beta \ln(x) + \varepsilon) - a - bx \\ &= (\alpha - a) + [\beta \ln(x) - bx] + \varepsilon \\ E[u|x] &= (\alpha - a) + \beta \ln(x) - bx \neq 0 \end{aligned}$$

b)

$$\begin{aligned} \hat{b}^{MQO} &= \frac{\widehat{cov}(Y, X)}{\widehat{V}(X)} = \frac{\widehat{cov}(\alpha + \beta \ln X + \varepsilon, X)}{\widehat{V}(X)} = \beta \frac{\widehat{cov}(\ln X, X)}{\widehat{V}(X)} + \frac{\widehat{cov}(\varepsilon, X)}{\widehat{V}(X)} \\ \text{plim}(\hat{b}^{MQO}) &= \beta \frac{\widehat{cov}(\ln X, X)}{\widehat{V}(X)} \neq \beta \end{aligned}$$

□

Exercício 8. Você agora é um analista em uma sala de situação (por exemplo em uma crise de covid), onde novas informações chegam instantaneamente. Sua amostra, portanto, cresce constantemente $(N, N + 1, \dots)$. Os parâmetros de interesse para responder a uma pergunta com significado econômico são β , em um modelo $y = \mathbf{x}'\boldsymbol{\beta} + \varepsilon$, onde $E[\varepsilon|\mathbf{X}] = 0$.

a) Mostre que

$$\hat{\beta}_{(N+1)}^{MQO} = \hat{\beta}_{(N)} + \left[\frac{1}{1 + \mathbf{x}'_{N+1}(\mathbf{X}'_N \mathbf{X}_N)^{-1} \mathbf{x}_{N+1}} \right] (\mathbf{X}'_N \mathbf{X}_N)^{-1} \mathbf{x}_{N+1} (y_{N+1} - \mathbf{x}'_{N+1} \hat{\beta}_{(N)}^{MQO})$$

onde \mathbf{X}_n representa a matriz $X = \begin{bmatrix} 1 & x_{11} & \dots & x_{K1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & \dots & x_{Kn} \end{bmatrix}$ para as primeiras n observações, e x_i representa o vetor $[1 \quad x_{1i} \quad \dots \quad x_{Ki}]'$ para o i -ésimo indivíduo.

b) Seja $\hat{y}_N(\mathbf{x}_0) = \mathbf{x}'_0(\mathbf{X}'_N \mathbf{X}_N)^{-1} \mathbf{X}'_N \mathbf{y}_N$ sua melhor previsão linear para y caso $\mathbf{x} = \mathbf{x}_0$, e sua estimação tenha partido de uma amostra original de tamanho N . Mostre que se $\hat{y}_N(\mathbf{x}_{N+1}) = y_{N+1}$, então $\hat{\beta}_{(N+1)}^{MQO} = \hat{\beta}_{(N)}^{MQO}$, e conclua que sua estimação só se altera se novos valores de y não puderem ser perfeitamente preditos a partir das observações anteriores de x e y .

Resposta: Você precisa saber que $X'X = \sum x_i x'_i$ e conhecer (ou derivar) a fórmula de Sherman-Morrison:

$$[A + x x']^{-1} = A^{-1} - \frac{A^{-1} x x' A^{-1}}{1 + x' A^{-1} x}$$

a) Sejam $\underset{K \times K}{A} \equiv \underset{K \times N}{X'_N} \underset{N \times K}{X_N}$, e $x_{N+1} = [1 \quad x_{1,N+1} \quad \dots \quad x_{K,N+1}]'$ o elemento $N+1$ de X_{N+1} , então

$$\underset{K \times N+1}{X'_{N+1}} \underset{N+1 \times K}{X_{N+1}} = \underset{K \times K}{A} + \underset{K \times 1}{x_{N+1} x'_{N+1}} \underset{1 \times K}{1}$$

Da mesma maneira, temos que

$$\underset{K \times N}{X'_{N+1}} \underset{N+1 \times 1}{Y_{N+1}} = \underset{K \times N}{X'_N} \underset{N \times 1}{Y_N} + \underset{K \times 1}{x_{N+1}} \underset{1 \times 1}{y_{N+1}},$$

em que y_{N+1} é o elemento $N+1$ do vetor Y_{N+1} .

Logo, os estimadores $\hat{\beta}_{N+1}^{MQO}$ e $\hat{\beta}_N^{MQO}$ podem ser escritos como

$$\hat{\beta}_N = (X'_N X_N)^{-1} X'_N Y_N = A^{-1} X'_N Y_N \quad (A \equiv X'_N X_N)$$

$$\hat{\beta}_{N+1} = (X'_{N+1} X_{N+1})^{-1} X'_{N+1} Y_{N+1} = [A + x_{N+1} x'_{N+1}]^{-1} [X'_N Y_N + x_{N+1} y_{N+1}] \quad (1)$$

$$\begin{aligned} &= \left[A^{-1} - \frac{A^{-1} x_{N+1} x'_{N+1} A^{-1}}{1 + x'_{N+1} A^{-1} x_{N+1}} \right] [X'_N Y_N + x_{N+1} y_{N+1}] \\ &= A^{-1} X'_N Y_N + A^{-1} x_{N+1} y_{N+1} - \frac{A^{-1} x_{N+1} x'_{N+1} A^{-1}}{1 + x'_{N+1} A^{-1} x_{N+1}} [X'_N Y_N + x_{N+1} y_{N+1}] \quad (2) \end{aligned}$$

Usando (1) em (2), temos que

$$\begin{aligned}
\hat{\beta}_{N+1} &= \hat{\beta}_N + A^{-1}x_{N+1}y_{N+1} - \frac{A^{-1}x_{N+1}x'_{N+1}A^{-1}}{1 + x'_{N+1}A^{-1}x_{N+1}} (X'_N Y_N + x_{N+1}y_{N+1}) \\
&= \hat{\beta}_N + \frac{A^{-1}x_{N+1}}{1 + x'_{N+1}A^{-1}x_{N+1}} [(1 + x'_{N+1}A^{-1}x_{N+1})y_{N+1} - x'_{N+1}A^{-1}(X'_N Y_N + x_{N+1}y_{N+1})] \\
&= \hat{\beta}_N + \frac{A^{-1}x_{N+1}}{1 + x'_{N+1}A^{-1}x_{N+1}} [y_{N+1} + x'_{N+1}A^{-1}x_{N+1}y_{N+1} - x'_{N+1}A^{-1}X'_N Y_N - x'_{N+1}A^{-1}x_{N+1}y_{N+1}] \\
&= \hat{\beta}_N + \frac{A^{-1}x_{N+1}}{1 + x'_{N+1}A^{-1}x_{N+1}} [y_{N+1} - x'_{N+1}A^{-1}X'_N Y_N] \\
&= \hat{\beta}_N + \frac{A^{-1}x_{N+1}}{1 + x'_{N+1}A^{-1}x_{N+1}} [y_{N+1} - x'_{N+1}\hat{\beta}_N] \quad (\hat{\beta}_N = A^{-1}X'_N Y_N) \\
&= \hat{\beta}_N + \frac{(X'_N X_N)^{-1}x_{N+1}}{1 + x'_{N+1}(X'_N X_N)^{-1}x_{N+1}} [y_{N+1} - x'_{N+1}\hat{\beta}_N] \quad (A \equiv X'_N X_N)
\end{aligned}$$

b) É fácil ver que, se $y_{N+1} - x'_{N+1}\hat{\beta}_N = 0$, logo

$$\hat{\beta}_{N+1} = \hat{\beta}_N.$$

□

Exercício 9. Seu modelo é $y = a + bx + \varepsilon$, porém $f(\varepsilon) = \lambda e^{-\lambda\varepsilon}$.

a) Calcule $E[\varepsilon|x]$ e $Var[\varepsilon|x]$ nesse caso.

b) Se você estimar a e b por MQO estes estimadores são consistentes? São viesados? Se sim, calcule qual o viés. Se não, demonstre.

Resposta: Havia erro no enunciado, considere que $f(\varepsilon) = \lambda e^{-\lambda\varepsilon}$

a) Como $\varepsilon \perp x$, então

$$\begin{aligned}
E[\varepsilon|x] &= E[\varepsilon] = \lambda^{-1} \\
V[\varepsilon|x] &= V[\varepsilon] = \lambda^{-2}
\end{aligned}$$

b) Note que

$$\hat{b} = b + \frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2}$$

Logo,

$$\begin{aligned}
E(\hat{b}|x) &= b + \frac{E[\sum (x_i - \bar{x})\varepsilon_i|x]}{\sum (x_i - \bar{x})^2} \\
&= b + \frac{1}{\sum (x_i - \bar{x})^2} \sum (x_i - \bar{x}) E[\varepsilon_i|x] \\
&= b + \frac{1}{\sum (x_i - \bar{x})^2} \sum (x_i - \bar{x}) \lambda^{-1} \\
&= b \implies \hat{b} \text{ é não-viesado}
\end{aligned}$$

Já para a temos:

$$\hat{a} = \bar{y} - \hat{b}\bar{x} = a + (b - \hat{b})\bar{x} + \bar{\varepsilon}$$

Portanto,

$$\begin{aligned} E[\hat{a}|x] &= a + \overbrace{E[(b - \hat{b})\bar{x}|x]}^0 + E[\bar{\varepsilon}|x] \\ &= a + \lambda^{-1} \implies \hat{a} \text{ é viesado} \end{aligned}$$

□

Exercício 10. Suponha que você esteja interessado(a) em estimar a proporção de pobres (isto é, a proporção de pessoas com renda y abaixo de uma linha de pobreza, L) no Brasil a partir da PNAD. Ou seja, seu parâmetro de interesse é $\theta = F_y(L) = \Pr(Y < L)$. Você tem acesso a uma base de dados com observações (iid) de renda para N indivíduos.

a) Seu primeiro estimador é $T = \frac{1}{N} \sum_{i=1}^N d_i$, onde d é uma variável dummy que indica se a renda está abaixo da linha da pobreza, ou seja, $d_i = 1 \iff y_i < L$. Encontre $E(T)$ e $\text{Var}(T)$. T é não-viesado? T é consistente?

b) Qual a distribuição assintótica de T ?

c) Suponha agora que adicionalmente você saiba que $y \sim N(\mu, \sigma^2)$, com σ^2 conhecida. Nesse caso, você agora sabe que $\theta = \Phi\left(\frac{L-\mu}{\sigma}\right)$, onde o símbolo Φ denota a função de distribuição Normal-Padrão. Considere o estimador alternativo $U = \Phi\left(\frac{L-\bar{y}}{\sigma}\right)$. U é não-viesado? U é consistente?

d) Qual a distribuição assintótica de U ?

e) Qual estimador você prefere? Dica: $\frac{\phi^2(z)}{\Phi(z)[1-\Phi(z)]} < 0,64$ para qualquer valor de z .

Resposta:

a)

$$\begin{aligned} E(T) &= E\left[\frac{1}{N} \sum_{i=1}^N d_i\right] = \frac{1}{N} \sum_{i=1}^N E[d_i] = \frac{1}{N} \sum_{i=1}^N \Pr(d_i = 1) \\ &= \frac{1}{N} \sum_{i=1}^N \Pr(y_i < L) = \frac{1}{N} \sum_{i=1}^N \theta = \frac{N\theta}{N} = \theta \implies \text{não-viesado} \\ V(T) &= v\left[\frac{1}{N} \sum_{i=1}^N d_i\right] = \frac{1}{N^2} \sum_{i=1}^N V(d_i) = \frac{1}{N^2} \sum_{i=1}^N \theta(1-\theta) = \frac{\theta(1-\theta)}{N} \\ \text{plim}(T) &= E(T) = \theta \text{ (aplicação direta da LGN)} \end{aligned}$$

b)


$$\begin{aligned} \sqrt{N}(T - \theta) &\xrightarrow{d} N[0; \theta(1-\theta)] \\ T &\xrightarrow{A} N\left[\theta; \frac{1}{N}\theta(1-\theta)\right] \end{aligned}$$

c)

$$\begin{aligned}
 plim(U_N) &= plim \left[\Phi \left(\frac{L - \bar{y}}{\sigma} \right) \right] \\
 &= \Phi \left(\frac{L - plim(\bar{y})}{\sigma} \right) \quad (\text{por Slutsky/mapeamento contínuo}) \\
 &= \Phi \left(\frac{L - \mu}{\sigma} \right) = \theta
 \end{aligned}$$

$$E(U_N) = E \left[\Phi \left(\frac{L - \bar{y}}{\sigma} \right) \right] \leq \Phi \left(\frac{L - E(\bar{y})}{\sigma} \right) = \theta, \quad \text{se } \Phi'' \left(\frac{L - E(\bar{y})}{\sigma} \right) \leq 0$$

Em geral, $E(U_N) > \theta$



d) Método Delta:

$$\begin{aligned}
 f(\bar{y}) &\approx f(\mu) + f'(\mu)(\bar{y} - \mu) \\
 U_N &\approx \theta + \frac{\partial \Phi}{\partial \mu}(\bar{y} - \mu) \\
 U_N - \theta &\approx \frac{\phi}{\sigma^2} \left(\frac{L - \mu}{\sigma} \right) (\bar{y} - \mu) \\
 \sqrt{N}(U_N - \theta) &\approx \sqrt{N} \frac{\phi}{\sigma^2} \left(\frac{L - \mu}{\sigma} \right) (\bar{y} - \mu) \stackrel{A}{\sim} N \left[0; \phi^2 \left(\frac{L - \mu}{\sigma} \right) \right] \\
 U_N &\stackrel{A}{\sim} N \left[\theta; \frac{1}{N} \phi^2 \left(\frac{L - \mu}{\sigma} \right) \right]
 \end{aligned}$$

e) U atinge o limite inferior de Cramer-Rao. Outra forma de ver isso é:

Para todo z :

$$\frac{\phi^2(z)}{\Phi(z)[1 - \Phi(z)]} < 0,64$$

Logo,

$$\phi^2(z) = 0,64\Phi(z)[1 - \Phi(z)] < \Phi(z)[1 - \Phi(z)]$$

Para $z = (L - \mu)/\sigma$:

$$\phi^2 \left(\frac{L - \mu}{\sigma} \right) = \text{Var}(U) < \Phi \left(\frac{L - \mu}{\sigma} \right) \left[1 - \Phi \left(\frac{L - \mu}{\sigma} \right) \right] = \theta(1 - \theta) = \text{Var}(T)$$

□

Exercício 11. a) Considere o modelo $y = a + \varepsilon$, com $E(\varepsilon) = 0$; $cov(\varepsilon_i, \varepsilon_j) = \delta^2$ e $var(\varepsilon_i) = \sigma^2 + \delta^2$. Calcule os estimadores de MQO e MQG para este caso e suas respectivas variâncias. Compute a eficiência relativa de MQG através de $\frac{var(\hat{a}^{MQG})}{var(\hat{a}^{MQO})}$.

b) Agora considere o caso em que $cov(\varepsilon_i, \varepsilon_j) = 0$ e $var(\varepsilon_i) = i\sigma^2$. Como fica sua resposta? O que você aprende com estes dois casos?

Resposta:

a)

$$\begin{aligned} var(\varepsilon) &= E(\varepsilon\varepsilon') = \sigma^2 I + \delta^2 \iota\iota' = \Omega \\ \hat{\mu}^{MQO} &= \bar{y} \\ \hat{\mu}^{MQG} &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y \end{aligned} \quad (\text{em que } X = \iota)$$

$$\begin{aligned} var(\hat{y}^{MQO}) &= (X'X)^{-1}X'\Omega X(X'X)^{-1} = \frac{1}{N^2}X'\Omega X = \frac{1}{N^2}\iota'[\sigma^2 I + \delta^2 \iota\iota']\iota \\ &= \frac{\sigma^2 \iota'\iota + \delta^2 \iota'\iota\iota'}{N^2} = \frac{\sigma^2 N + \delta^2 N^2}{N^2} = \frac{\sigma^2 + \delta^2 N}{N} \end{aligned}$$

Obtendo Ω^{-1} por chute $\rightarrow \Omega^{-1} = \gamma_0 I + \gamma_1 \iota\iota'$

$$\begin{aligned} \gamma_0 I \sigma^2 I + \gamma_0 I \delta^2 \iota\iota' + \gamma_1 \iota\iota' \sigma^2 I + \gamma_1 \delta^2 \iota\iota' \iota\iota' &= I \\ \gamma_0 \sigma^2 I + \delta^2 \gamma_0 \iota\iota' + \gamma_1 \sigma^2 \iota\iota' + N \gamma_1 \delta^2 \iota\iota' &= I \end{aligned}$$

$$\left. \begin{aligned} \gamma_0 \sigma^2 &= 1 \\ \delta^2 \gamma_0 + \sigma^2 \gamma_1 + N \gamma_1 \sigma^2 &= 0 \end{aligned} \right\} \quad \begin{aligned} \gamma_0 &= \frac{1}{\sigma^2} \\ \gamma_1 &= -\frac{\delta^2}{\sigma^2(\sigma^2 + N\delta^2)} \end{aligned}$$

$$\begin{aligned} var(\hat{y}^{MQG}) &= (X'\Omega^{-1}X)^{-1} = [\iota'(\gamma_0 I + \gamma_1 \iota\iota')\iota]^{-1} = [\gamma_0 \iota'\iota + \gamma_1 \iota'\iota\iota']^{-1} \\ &= (\gamma_0 N + \gamma_1 N^2)^{-1} = \left[\frac{N}{\sigma^2} - \frac{\delta^2 N^2}{\sigma^2(\sigma^2 + N\delta^2)} \right]^{-1} \\ &= \left[\frac{N(\sigma^2 + N\delta^2) - \delta^2 N^2}{\sigma^2(\sigma^2 + N\delta^2)} \right]^{-1} = \left[\frac{N^2 \delta^2}{\sigma^2(\sigma^2 + N\delta^2)} \right]^{-1} \\ &= \left[\frac{N^2}{\sigma^2 + N\delta^2} \right]^{-1} = \frac{\sigma^2 + N\delta^2}{N^2} = var(\hat{\mu}^{MQO}) \\ \hat{y}^{MQG} &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y = [\iota'(\gamma_0 I + \gamma_1 \iota\iota')\iota]^{-1}\iota'[\gamma_0 I + \gamma_1 \iota\iota'] \\ &= [N\gamma_0 + N^2\gamma_1]^{-1} \left[\gamma_0 \sum_{i=1}^N y_i + N\gamma_1 \sum_{i=1}^N y_i \right] = \frac{\gamma_0 + N\gamma_1}{N(\gamma_0 + N\gamma_1)} \sum_{i=1}^N y_i \\ &= \bar{y} = \hat{y}^{MQO} \end{aligned}$$

b) MQO:

$$\hat{a} = \bar{y}$$

$$V(\hat{a}) = \frac{\sigma^2 I}{N^2} \iota' \Omega \iota = \frac{\sigma^2 I}{N^2} \sum_{i=1}^N i = \frac{\sigma^2 I}{N^2} \frac{N(N+1)}{2} = \frac{\sigma^2 I(N+1)}{2N}$$

MQG:

$$\hat{a} = \sum_{i=1}^N w_i y_i \quad ; \quad w_i = \frac{i^{-1}}{\sum_{i=1}^N i^{-1}}$$

$$V(\hat{a}) = \sum_{i=1}^N V(w_i y_i) = \sum_{i=1}^N w_i^2 V(\varepsilon_i) = \sum_{i=1}^N w_i^2 \sigma_i^2 = \frac{\sum_{i=1}^N \sigma^2}{(\sum_{i=1}^N w_i^2)^2} = \frac{N \sigma^2}{(\sum_{i=1}^N w_i^2)^2}$$

A correlação de ε não afetou a estimação de \hat{a} , mas a heteroscedasticidade sim.

□

Exercício 12. Considere o modelo já em desvios com respeito à média: $y = ax_1 + bx_2 + \varepsilon$, onde $E[\varepsilon|x_1, x_2] = 0$, porém $E[\varepsilon^2|x_1, x_2] = \alpha x_1^2 + \beta x_2^2$.

- Derive a distribuição assintótica de $\hat{\gamma}^{MQO} = [\hat{a} \quad \hat{b}]'$
- Como você estimaria a matriz de variâncias e covariâncias assintótica de $\hat{\gamma}^{MQO}$?
- Como você testaria a hipótese $a/b = 1$?
- Explique como você construiria um estimador $\hat{\gamma}^{MQGf}$, e derive sua distribuição assintótica.

Resposta:

a)

$$\sqrt{N}(\hat{\gamma} - \gamma) \stackrel{d}{\sim} N(0; E(xx')^{-1} E(\varepsilon^2 xx') E(xx')^{-1})$$

Como:

$$E(\varepsilon^2 xx') = E_x [(\alpha x_1^2 + \beta x_2^2) xx']$$

$$\equiv E(x' A x x'), \quad \text{em que } A \equiv \begin{bmatrix} \alpha & 0 \\ 0 & \beta \end{bmatrix}$$

Logo,

$$\sqrt{N}(\hat{\gamma} - \gamma) \stackrel{d}{\sim} N(0; E(xx')^{-1} E(x' A x x') E(xx')^{-1})$$

b) 1º estágio: MQO

$$\hat{\gamma} = (X'X)^{-1}X'y \quad ; \quad \hat{\varepsilon} = y - \hat{\beta}$$

2º estágio: $\hat{\varepsilon}_i^2 = \alpha X_{1i}^2 + \beta X_{2i}^2 + u$, logo

$$\text{MQO:} \quad \begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} = ((x^2)'x^2)^{-1} (x^2)'\hat{\varepsilon}^2$$

$$\hat{\Omega} = \frac{1}{N} \sum_{i=1}^N (\hat{\alpha}x_{1i}^2 + \hat{\beta}x_{2i}^2)x_i^{-2}x_i^{-2}$$

c) $H_0 : \frac{a}{b} = 1 \iff H_0 : a = b \iff a - b = 0$

$$\text{Seja } r = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \implies H_0 : r'\gamma = 0$$

Teste z (assintótico): $r'\gamma \sim N(r'\gamma; r'V(\hat{\gamma})r)$

$$z^* = \frac{r'\hat{\gamma}}{\sqrt{r'V(\hat{\gamma})r}} \sim N(0, 1)$$

d) 1º estágio: MQO

$$\hat{\gamma} = (X'X)^{-1}X'y \quad ; \quad \hat{\varepsilon} = y - \hat{\beta}$$

2º estágio: $\hat{\varepsilon}_i^2 = \alpha X_{1i}^2 + \beta X_{2i}^2 + u$, logo

$$\text{MQO:} \quad \begin{bmatrix} \hat{\alpha} \\ \hat{\beta} \end{bmatrix} = ((x^2)'x^2)^{-1} (x^2)'\hat{\varepsilon}^2$$

$$\hat{\Omega} = \frac{1}{N} \sum_{i=1}^N (\hat{\alpha}x_{1i}^2 + \hat{\beta}x_{2i}^2)x_i^{-2}x_i^{-2}$$

3º estágio:

$$\hat{\gamma}^{MQGf} = (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y \stackrel{a}{\sim} N[\gamma; N^{-1}(X'\hat{\Omega}^{-1}X)^{-1}]$$

□

Exercício 13. Considere o modelo: $y = c + ax_1 + bx_2 + \varepsilon$, onde $E[\varepsilon|x_1, x_2] = 0$, $E[\varepsilon^2|x_1, x_2] = \sigma^2$. O problema agora é que, para x_1 , as últimas $N - J$ observações estão faltando (missing data). Avalie os seguintes três procedimentos:

- Descarte as últimas J observações de sua amostra. Nesse caso MQO ainda seria não-viesado? Justifique
- Suponha que x_1 possa ser modelado através da relação $x_1 = \mathbf{z}'\gamma + \mathbf{u}$, para um conjunto de variáveis \mathbf{z} disponível para toda a amostra, e onde $E[u|z] = 0$; $E[\mathbf{u}\mathbf{u}'|Z] = \delta^2\mathbf{I}$, e $E[u\varepsilon|\mathbf{z}, x] = 0$. Nesse caso, você poderia, nas primeiras $N - J$ observações, estimar $\hat{\gamma}$ e posteriormente imputar $\hat{x}_{1i} = \mathbf{z}_i'\hat{\gamma}$ às últimas J observações e desse modo completar a base de dados para poder fazer MQO. Este procedimento resulta em estimativas não-viesadas para (a, b, c) ? Seriam elas ao menos consistentes?

c) No procedimento anterior, há um erro de medida em parte da amostra, $\eta_i = x_{1i} - \hat{x}_{1i}$. No item anterior já deveríamos ter discutido potencial viés, mas além disso há aqui um problema de heterocedasticidade. Desenvolva um estimador MQGf para lidar com este problema. Este procedimento é assintoticamente eficiente?

Resposta:

a) Seja $A = 1$ o evento X presente e $A = 0$ o ausente (*missing*). Então,

$$E(\varepsilon|X) = E(\varepsilon|X, A = 1) \cdot Pr(A = 1|X) + E(\varepsilon|X, A = 0) \cdot Pr(A = 0|X) = 0$$

$$E(\varepsilon|X, A = 1) = -\frac{Pr(A = 0|X)}{Pr(A = 1|X)} E(\varepsilon|X, A = 0)$$

2 condições para $E(\varepsilon|X, A = 1) = 0$:

- $Pr(A = 0|X) = 0$ (não há atrito)

ou

- $E(\varepsilon|X, A = 1) = E(\varepsilon|X) \implies A \perp\!\!\!\perp \varepsilon|X$ (*missing at random*)

Se $E(\varepsilon|X, A = 1) = 0$, então MQO é não-viesado.

b) Seja

$$\tilde{X} = \begin{bmatrix} X_J \\ \hat{X}_{N-J} \end{bmatrix} ; \quad \hat{X}'_i = [1 \quad z_i \hat{\gamma} \quad X_{2i}]$$

$$y = \tilde{X}\beta + v ; \quad v = \begin{bmatrix} \varepsilon \\ \varepsilon + (X - \hat{X})\beta \end{bmatrix}$$

Note que

$$E(\varepsilon|X) = 0 \not\implies E(v|\tilde{X}) = 0,$$

pois seria necessário $E(\varepsilon|X, Z) = 0$. Logo, $\hat{\beta}$ é, em geral, viesado.

Observe, contudo, que

$$plim(\hat{\gamma}) = \gamma \implies \hat{X} \xrightarrow{p} x - u$$

$$\begin{aligned} \hat{\beta} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y = \left(\frac{1}{N}\sum \tilde{x}_i\tilde{x}'_i\right)^{-1}\left(\frac{1}{N}\sum \tilde{x}_iy_i\right) \\ &= \begin{bmatrix} \frac{X'_J X_J}{N} & \frac{X'_J \hat{X}_{N-J}}{N} \\ \frac{\hat{X}'_{N-J} X_J}{N} & \frac{\hat{X}'_{N-J} \hat{X}_{N-J}}{N} \end{bmatrix}^{-1} \begin{bmatrix} \frac{X'_J}{N} \\ \frac{\hat{X}'_{N-J}}{N} \end{bmatrix} Y, \end{aligned}$$

em que:

$$\begin{aligned}
plim \left(\frac{X'_J X_J}{N} \right) &= E(x_J x'_J) \\
plim \left(\frac{\hat{X}'_{N-J} X_J}{N} \right) &= plim \left(\frac{(X'_{N-J} + u)' X_J}{N} \right) = E(x_{N-J} x'_J) + \cancel{plim \left(\frac{u' x'_J}{N} \right)} \xrightarrow{0} \\
plim \left(\frac{\hat{X}'_{N-J} \hat{X}_{N-J}}{N} \right) &= plim \left(\frac{X'_{N-J} X_{N-J}}{N} \right) + plim \left(\frac{u' u}{N} \right) + 0 = E(x_{N-J} x'_{N-J}) + \Sigma_v \\
\implies plim \left(\frac{\tilde{X}' \tilde{X}}{N} \right) &= E(xx') + \Sigma_{vv} \neq E(xx'),
\end{aligned}$$

em que

$$\Sigma_{vv} = \begin{bmatrix} 0 & 0 \\ 0 & \Sigma_v \end{bmatrix}$$

Logo,

$$\begin{aligned}
plim \left(\frac{\tilde{X}' \tilde{X}}{N} \right)^{-1} &= [E(xx') + \Sigma_{vv}]^{-1} \\
plim \left(\frac{\tilde{X}' Y}{N} \right) &= \begin{bmatrix} E(x_J y) \\ plim \left(\frac{\hat{x} y}{N} \right) \end{bmatrix} = \begin{bmatrix} E(x_J y) \\ E(x_{N-J} y) \end{bmatrix} = E(xy) \\
plim \hat{\beta} &= [E(xx') + \Sigma_{vv}]^{-1} E(xy) \neq \beta
\end{aligned}$$

c) Nas primeiras J observações, podemos calcular

$$\hat{V} = x - \hat{x} \quad \text{e} \quad S_v^2 = \frac{1}{J - K_z} \implies \sum_J \hat{v}^2 = \begin{bmatrix} 0 & 0 \\ 0 & I_{N-J} \end{bmatrix} S_v^2$$

Podemos formar

$$\tilde{\tilde{X}}' \tilde{\tilde{X}} = \tilde{X}' \tilde{X} - \Sigma_{vv}$$

logo,

$$\begin{aligned}
\tilde{\tilde{\beta}} &= (\tilde{\tilde{X}}' \tilde{\tilde{X}})^{-1} \tilde{\tilde{X}}' Y \xrightarrow{p} \beta \\
\tilde{\tilde{\varepsilon}} &= Y - X \tilde{\tilde{\beta}} \\
\hat{\Omega} &= \frac{1}{N} \sum \tilde{\tilde{\varepsilon}}_i^2 \tilde{\tilde{x}}_i \tilde{\tilde{x}}_i^2
\end{aligned}$$

Assim,

$$\hat{\beta}^{MQGf} = A \tilde{X}' \hat{\Omega}^{-1} Y, \quad \text{em que } A = \tilde{X}' \hat{\Omega}^{-1} \tilde{X} = \hat{\Sigma}_{vv}$$

□

Exercício 14. Suponha que seu modelo seja $y = a + bx + \varepsilon$, e que as hipóteses populacionais de Gauss-Markov sejam satisfeitas. No entanto, sua amostra foi coletada em um desenho onde, inicialmente, a população original foi dividida em J grupos tal que o tamanho do grupo 1 é 1, o tamanho do grupo 2 é 2 e assim por diante até que o j -ésimo grupo tem tamanho j , de modo que ao final $\sum_{j=1}^J n_j = N$. Infelizmente, contudo, você tem acesso somente às médias amostrais de cada grupo \bar{y}_j , \bar{x}_j .

- a) Como você lidaria com a situação? Simplesmente formaria uma base de dados com J entradas e aplicaria MQO? Este procedimento acarretaria em estimadores consistentes? Qual seria a variância de $b^{MQO(J)}$ nesse caso?
- b) Encontre o estimador de MQGf nesse caso.

Resposta:

- a) A regressão agora fica

$$\bar{y}_j = \bar{x}_j' \beta u_j$$

em que $\bar{y}_j = \frac{1}{j} \sum_{k=1}^J y_k^{(j)}$, sendo $y_k^{(j)}$ a k -ésima observação no grupo j .

$$\varepsilon_k \sim N(0, \sigma^2) \implies u_j \sim N\left(0; \frac{\sigma^2}{j}\right)$$

Logo,

$$\Omega = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1/2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 1/J \end{bmatrix} \implies \Omega^{-1} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & J \end{bmatrix}$$

MQO é consistente, porém $Avar(\hat{\beta}^{MQO}) = (\hat{X}'\hat{X})^{-1}\bar{X}'\Omega\bar{X}(\hat{X}'\hat{X})^{-1}$

- b) $\hat{\beta}^{MQGf} = (\bar{X}'\Omega^{-1}\bar{X})^{-1}\bar{X}'\Omega^{-1}\bar{y}$

□